

Cahier des charges

Last updated by | Youssef Bouattour | Jul 16, 2026 at 12:02 AM GMT+1

Cahier des charges — Agent RAG pour l'automatisation du traitement et de la digitalisation des factures et devis

Durée du stage : 8 semaines

1. Contexte métier

Ce stage porte sur l'automatisation du traitement des factures et devis reçus par une entreprise : aujourd'hui, ces documents sont traités et saisis manuellement dans les outils de facturation, ce qui prend du temps et génère des erreurs.

Le besoin concret : transformer automatiquement une facture ou un devis (PDF, scan, formats variés selon les fournisseurs) en données structurées exploitables (fournisseur, montants, lignes, dates), les valider, et les intégrer dans un outil de facturation — avec, en complément, la possibilité d'interroger l'historique des factures en langage naturel.

2. Objectif du stage

Concevoir et prototyper une solution hybride combinant **extraction automatique de documents (IDP)** et **RAG** pour :

- extraire automatiquement les champs clés d'une facture/devis (fournisseur, montant, date, lignes de détail) ;
- valider la cohérence des données extraites ;
- structurer et stocker ces données ;
- intégrer les données dans un outil de facturation cible ;
- permettre, en complément, des requêtes en langage naturel sur l'historique des factures indexées.

3. Comprendre le sujet : IDP et RAG

Ce projet combine deux approches différentes — bien comprendre laquelle s'applique à quelle partie du problème est important.

A) IDP — Intelligent Document Processing


Facture/devis → OCR + extraction structurée (champs clés) → Validation métier → Stockage structuré → In

C'est de l'**extraction ciblée de champs** (montant, date, fournisseur...), pas de la recherche sémantique libre. Des outils spécialisés existent déjà pour ça (voir section 6) — l'enjeu n'est pas de les reconstruire mais de les intégrer et de les fiabiliser.

B) RAG — pour les requêtes transverses



Question en langage naturel ("factures impayées du fournisseur X ?") → Recherche dans les factures indexées



C'est la même logique que dans un RAG classique de questions/réponses documentaires, appliquée ici à l'historique des factures déjà traitées.

Concepts clés à maîtriser avant de coder (recherchez, lisez, expérimentez) :

Extraction structurée / IDP

Extraire des champs précis et typés (pas juste du texte brut) à partir d'un document.

Modèle prébuilt vs custom

Un modèle prébuilt (ex: AI Builder "Traitement de factures") est déjà entraîné sur des factures génériques ; un modèle custom demande d'entraîner sur vos propres documents.

Validation métier

Des règles simples (ex: montant TTC = HT + TVA) qui permettent de détecter automatiquement une extraction incorrecte.

Embedding / base vectorielle / prompt augmenté

Mêmes notions qu'un RAG classique — nécessaires pour la brique de recherche transverse (voir section 4.B).

4. Méthode de travail attendue

1. **Recherche autonome en amont de chaque brique.** Avant chaque nouvelle étape, vous devez explorer les solutions disponibles (**Power Platform, outils Azure gratuits, ou open source** selon la brique), comparer les options, et documenter pourquoi vous en choisissez une plutôt qu'une autre.
2. **Valider vos choix techniques avec le lead technique** avant de vous engager dans une implémentation lourde — en particulier le choix entre solution Power Platform (rapide, low-code) et solution custom codée (plus flexible, plus longue).
3. **Tester tôt et souvent** sur des documents réels, pas seulement sur des cas idéaux.
4. **Documenter au fur et à mesure**, pas seulement à la fin.
5. **Poser des questions** au lead technique dès qu'un blocage dépasse quelques heures de recherche infructueuse.

5. Organisation du travail

Le travail est découpé en **Backlog Items** (une feature = une brique du pipeline), eux-mêmes découpés en **Tasks** (unités de travail concrètes, dans l'ordre où elles doivent être traitées). Chaque Backlog Item et chaque Task ont une description, des critères d'acceptation (checklist) et une estimation de charge en heures.

Ces tickets sont disponibles dans le Wiki/Boards Azure DevOps du projet. Un point hebdomadaire avec le lead technique permet de faire le point sur l'avancement et d'ajuster si besoin.

6. Contraintes et périmètre

- Stack limitée à : **IA / Power Platform / outils Azure gratuits / solutions open source**. Pas de budget pour des API payantes (privilégier les paliers gratuits ou l'auto-hébergement, ex: LLM local via Ollama).
- Approche **hybride** : utiliser Power Platform (AI Builder, Power Automate) pour aller vite là où c'est pertinent, et du code custom uniquement là où Power Platform ne suffit pas (ex: recherche sémantique transverse).
- Le périmètre est un **prototype fonctionnel**, pas une solution industrialisée — la démonstration de faisabilité et la qualité de la démarche priment sur une robustesse à 100%.

7. Livrables attendus en fin de stage

1. Un **prototype fonctionnel** du pipeline d'extraction et de digitalisation des factures/devis.
2. Une **documentation technique** décrivant l'architecture retenue (répartition Power Platform / custom) et les choix effectués.
3. Un **jeu de tests** couvrant plusieurs formats et fournisseurs de factures/devis.
4. Une **synthèse des résultats obtenus** (taux d'extraction correcte, limites observées).
5. Une **liste de recommandations** pour une version industrialisable future.
6. Un **rapport de stage** (voir section 9).

8. Rapport de stage — structure attendue

Le rapport de stage doit permettre à quelqu'un qui n'a pas suivi le stage de comprendre ce qui a été fait, comment, et pourquoi. Structure recommandée :

1. **Introduction** — contexte Dazzlifai, objectif du stage
2. **Notions théoriques** — explication de l>IDP et du RAG avec vos propres mots (preuve de compréhension, pas de copier-coller)
3. **Démarche et méthodologie** — comment vous avez recherché, comparé et choisi les solutions techniques (Power Platform vs custom)
4. **Réalisation** — semaine par semaine ou brique par brique, ce qui a été construit
5. **Difficultés rencontrées et solutions apportées**

6. **Résultats et évaluation** — chiffres, exemples concrets de factures traitées

7. **Limites identifiées et recommandations**

8. **Conclusion et apprentissages personnels**